

Lo que hay y lo que falta

Los datos están bajados y la pregunta ya tiene respuesta. Falta decidir cómo se reparte el trabajo y escribir la formulación, que se entrega el lunes 7.

01

La base está construida

Fuente: la API pública de World Aquatics. Temporada 2024, 12 pruebas × 2 sexos × 2 piscinas.

193.142 nados descargados	56.035 nadadores distintos	154 países	30.257 nadadores con marca en las dos piscinas
---	--	----------------------------------	--

Ese último número es el que importa: son los nadadores que se pueden **comparar consigo mismos** entre piscina de 25 y de 50. Cada uno aporta un par. Comparar a alguien con su propia marca elimina talento, edad y entrenamiento como variables de confusión.

Cero valores faltantes, cero duplicados, cero tiempos fuera de rango. El mínimo por combinación de sexo × estilo × distancia es 570 casos.

02


El resultado

1,5% → 5,2%

Eso es lo que varía el factor de conversión entre piscinas según la prueba.
Un extremo es más de tres veces el otro. Hoy se usa un solo número para todas.

Segundos que regala cada vuelta extra, en los 200 metros

Mediana sobre los nadadores con marca en ambas piscinas, 2024



Una vuelta en espalda vale casi el doble que una en libre. Y el orden de los estilos es idéntico en hombres y mujeres, sin una sola excepción.

La segunda señal: crece con la distancia

Dentro de cada estilo, la ventaja por vuelta no es constante. Estos son los valores del estilo libre masculino a cada distancia:

50 M	100 M	200 M	400 M
0,67	0,77	0,90	0,96

Crece en los diez casos, sin excepción. Hipótesis a contrastar con regresión: la fatiga penaliza más el nado en superficie que la vuelta.

Por qué el resultado se sostiene: tres regularidades se cumplen a la vez y ninguna estaba impuesta por el cálculo — el orden de los estilos es igual en ambos sexos, el valor crece con la distancia en los diez casos, y los hombres están arriba en las diez celdas comparables. Tres patrones independientes cumpliéndose juntos no es ruido.

03

Lo que aprendimos de la fuente

Esto responde el criterio 3 de la rúbrica, «restricciones de acceso», con evidencia propia. Casi ningún proyecto puede.

- La API no pagina. Probamos ocho nombres de parámetro — `page` , `pageNumber` , `pageIndex` , `offset` , `start` , `skip` , `from` , `firstResult` . Los ocho se ignoran.

- El techo por consulta son 5.000 filas. Con 10.000 responde 404.
- Hay que usar `timesMode=BEST_TIMES`, que da un nado por nadador. Con el otro modo, los 5.000 «mejores tiempos» del 100 libre los ponen 30 personas que compiten veinte veces al año.

Y UNA HISTORIA QUE VALE CONTAR EN EL INFORME

La primera versión del script asumía que la API paginaba. Como no lo hace, bajó seis veces la misma página: 28.800 filas de las que solo 4.800 eran distintas.

El script no falló. No tiró ningún error, imprimió «600 nados» cuarenta y ocho veces y terminó con un mensaje de éxito. El problema apareció recién al contar nadadores distintos y ver que el número no se movía por más profundo que bajáramos.

De ahí salieron los tres controles que ahora corren solos en cada descarga. La lección va derecho al informe: verificar no es «el script terminó sin errores», es contar algo que tenga que dar un número predecible.

04

Las opciones sobre la mesa

Siete preguntas posibles. Las seis primeras salen de los datos que ya están bajados.

PREGUNTA	QUÉ NECESITA	ESTADO
Factor de conversión entre piscinas	Lo que ya está	CON RESULTADO
Brecha entre sexos por prueba	Lo que ya está	DIRECTO
Edad de máximo rendimiento	Columnas <code>edad</code> , <code>person_id</code>	DIRECTO
Especialistas contra polivalentes	<code>person_id</code> cruzado entre pruebas	DIRECTO
Estacionalidad de las marcas rápidas	Columna <code>fecha</code>	DIRECTO
Profundidad competitiva por país	<code>pais</code> + <code>person_id</code>	DIRECTO
Estrategia de ritmo (parciales cada 50 m)	Segundo endpoint de la API	FALTA RESOLVER

Sobre los parciales

No están en el CSV: la tabla tiene un tiempo por nado, el final. Pero **sí existen en la API**, en el endpoint `/fina/events/{id}`, con el tiempo de cada tramo de 50 m.

Lo que falta es averiguar **qué columna del CSV sirve de llave** para enganchar las dos tablas. Hay tres candidatas — `event_id` , `discipline_id` , `result_id` — y ninguna está verificada todavía. Es un problema de programación acotado, de un par de horas.

05

Propuesta de reparto

El Capstone es **un** proyecto con **un** informe. Así que conviene dividirlo en dos mitades de la misma pregunta, no en dos investigaciones separadas.

JAVIER

Los parciales

Resolver la llave entre el ranking y el endpoint de resultados, y bajar los parciales de las competencias grandes.

- Es un problema técnico acotado
- Si sale, abre la pregunta más rica de las siete
- Si no sale, el plan B es tomar la pregunta de la edad o la de especialistas

FELIPE

El análisis

El factor de conversión con lo que ya está, más una segunda pregunta como sección descriptiva.

- Inferencia el martes 8: intervalos de confianza
- Regresión el jueves 10: la pendiente por estilo
- Redacción de la formulación

Por qué encajan: el factor de conversión mide *cuánto* regala una vuelta. Los parciales muestran *dónde* se regala. Es la misma pregunta a dos niveles de detalle, y juntas dan un informe mucho más sólido que cualquiera por separado.

06

Hasta el lunes 7

La formulación son 2 a 3 páginas en PDF, un envío por equipo. Cuatro de los cinco criterios ya tienen con qué responderse.

1. **Hoy:** elegir la segunda pregunta y quién toma qué.
2. **Martes 2:** Javier prueba la llave de los parciales. Felipe arma la sección descriptiva.
3. **Miércoles 3:** borrador de la formulación.
4. **Jueves 4:** clase — presentar la idea, sin nota. Corregir con lo que diga la profesora.
5. **Lunes 7:** entregar.

El único pendiente que preocupa

Falta buscar **cuál es el factor de conversión que se usa hoy en la práctica**, para tener contra qué comparar. Sin ese punto de referencia el resultado se queda en descriptivo; con él, el proyecto dice «el número que ustedes usan está mal en estos casos, y por esto».

Son 20 puntos de la rúbrica —el criterio de novedad e impacto— y es un rato de búsqueda bibliográfica. Vale la pena que alguien lo tome hoy.

