

Entrega 2 · Primer análisis exploratorio de datos

¿Es equivalente la exigencia para clasificar según el tipo de piscina en que se nade?
Felipe Leiva y Javier Fuentes · Diplomado en Ciencia de Datos Aplicada, UTFSM · Módulo 1 · martes 15 de septiembre de 2026

<https://github.com/fleivadiaz/capstone-natacion>

El repositorio es público, así que no hace falta ninguna invitación para abrirlo: el link basta. El entregable es el notebook **03_eda_capstone.ipynb**, ejecutado de principio a fin, que se ve renderizado en la propia página de GitHub.

Qué contiene el repositorio y en qué orden se ejecuta

La entrega consta de un notebook y dos scripts auxiliares que producen los archivos que ese notebook lee. El notebook no importa ningún otro archivo de la carpeta: con los dos insumos en su lugar, corre entero por sí solo.

Orden	Archivo	Qué hace
1	descargar.py	Descarga los rankings de la temporada 2024 desde la API de World Aquatics: 48 consultas (12 pruebas x 2 sexos x 2 piscinas) en modo BEST_TIMES, con caché local y pausa entre peticiones. Produce datos/nados.csv
2	factor_implicito_wa.py	Transcribe las marcas mínimas oficiales del Mundial de 25 m de Beijing 2026, calcula el factor de conversión implícito en ellas y su brecha contra el medido. Produce datos/comparacion_wa.csv, que sí va en el repositorio
3	03_eda_capstone.ipynb	El entregable. Lee esos dos archivos y calcula todo lo demás: limpieza, cruce dentro-nadador, descriptivos, bivariado, las cinco figuras y los hallazgos

El README del repositorio documenta además el resto de los archivos versionados: las tablas agregadas de datos/, las dos sondas con que se midieron las restricciones de la API, los scripts de respaldo de lo que se afirma en el texto y el material de las entregas anteriores.

Los datos crudos no se pueden compartir

Los términos legales de World Aquatics prohíben en su sección 3 la redistribución de sus contenidos. Por eso **datos/nados.csv** (62 MB, 193.142 filas) y la tabla de pares **datos/pares_lcm_scm.csv** no están en el repositorio, y así se declara en la primera celda del notebook. Para regenerarlos basta correr **uv run python capstone/descargar.py**: son 48 consultas con pausa entre ellas, unos minutos la primera vez, y el script cachea cada respuesta, de modo que una segunda corrida no vuelve a pedir nada. Sí van en el repositorio las tablas agregadas (comparacion_wa.csv, factores_por_prueba.csv, factor_por_nivel.csv, metadatos.md): son estadísticas por prueba y no contienen marcas individuales.

Dónde se cumple cada criterio de la rúbrica

Criterio	Sección del notebook
1. Los datos y su calidad	Sección 1. Tipos y nulos (1.1); faltantes disfrazados, con los dos centinelas encontrados (1.2); duplicados, verificados con assert (1.3); valores imposibles en segundos por metro (1.4); el cruce LCM-SCM con validate one_to_one y conteos antes y después (1.5); y la bitácora con las siete decisiones de limpieza (1.6)
2. Estadística descriptiva	Sección 2. Centro, dispersión, asimetría y curtosis de las seis variables relevantes, interpretadas en el contexto, más la declaración de que los rankings no traen factores de expansión y por lo tanto no se inventan
3. Análisis bivariado	Sección 3, con el objetivo declarado antes de cada análisis: factor contra distancia con Pearson y Spearman (3.1); el sesgo de selección por nivel (3.2); la matriz de correlación de Spearman (3.3); el factor por estilo (3.4); la tabla de contingencia sexo x estilo (3.5); y la brecha entre sexos con Mann-Whitney, prueba por prueba (3.6)
4. Visualización	Sección 4. Cinco gráficos de tipos distintos: histograma (4.1), boxplot (4.2), dispersión con hexbin y ejes logarítmicos, que es el tratamiento del overplotting y las colas largas (4.3), líneas (4.4) y barras (4.5). Todos con título, ejes rotulados con unidad e interpretación escrita
5. Hallazgos, código y reproducibilidad	Sección 5. Cinco hallazgos en frases completas, el modelo que se ajustará en el informe de avance (diferencia_s contra vueltas_extra, por estilo y sexo) y las cuatro limitaciones declaradas

Declaración de uso de inteligencia artificial

Se usó Claude (Anthropic) para explorar la documentación de la API de World Aquatics, discutir el diseño del análisis y revisar el código y la redacción. Los datos, las decisiones metodológicas y la interpretación son de los autores, que pueden explicar cada parte de lo entregado. La declaración está también en la primera celda del notebook.